



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO.  
IIMAS

**Calidad y Preproces. de Datos**

Semestre 2025-2.

Profesores: Víctor Manuel Corza Vargas

Cinthia Rodríguez Maya

---

### Practica 3

---

Integrantes:

- Aguilar Martínez Erick Yair
- Mendoza Hernández Carlos Emiliano
- Mendoza Sáenz de Buruaga Imanol
- Villalón Pineda Luis Enrique .

## SECCION 1


A. Busca en la página web de UCI o Kaggle un dataset que contenga outliers. Usamos el dataset se 'insurance'.

|   | age | sex    | bmi    | children | smoker | region    | charges     |
|---|-----|--------|--------|----------|--------|-----------|-------------|
| 0 | 19  | female | 27.900 | 0        | yes    | southwest | 16884.92400 |
| 1 | 18  | male   | 33.770 | 1        | no     | southeast | 1725.55230  |
| 2 | 28  | male   | 33.000 | 3        | no     | southeast | 4449.46200  |
| 3 | 33  | male   | 22.705 | 0        | no     | northwest | 21984.47061 |
| 4 | 32  | male   | 28.880 | 0        | no     | northwest | 3866.85520  |

B. Notemos algunos aspectos importantes:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1338 entries, 0 to 1337
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   age         1338 non-null   int64
1   sex         1338 non-null   object
2   bmi         1338 non-null   float64
3   children    1338 non-null   int64
4   smoker      1338 non-null   object
5   region      1338 non-null   object
6   charges     1338 non-null   float64
dtypes: float64(2), int64(2), object(3)
memory usage: 73.3+ KB
```

C. Demos un vistazo general de outliers en el data set



## I. Genera el reporte automático que se vio en clase para explicar el dataset

El documento se encuentra en el zip que se encia del trabajo ProfileReport es una clase de la biblioteca ydata-profiling la cual genera un informe detallado y automatizado del data frame que le pasamos como parámetro y se guarda como un archivo HTML interactivo.

## II. Menciona aspectos destacados del dataset mediante el reporte de gráficas del punto anterior

Se pueden destacar ciertas cosas a través de la información que el reporte nos proporciona:

- Hay mas números de beneficiarios principales que se encuentran entre los 18 y 19 años en comparación a las demás edades (casi el doble en comparación).
- El género para los beneficiarios es equitativo y el índice de masa corporal sigue una distribución normal aunque existen ciertos valores atípicos.
- La mayoría de los registros tienden a tener menos hijos y de igual manera no tienden a ser fumadores.
- Las ubicaciones en las cuales se les da el servicio a los beneficiarios están distribuidas de manera equitativa entre los cuatro valores/zonas categóricas.
- Los cargos para la mayoría de los registros están en lo mínimo cerca de 1121.8739
- Las correlaciones más fuertes se encuentran entre los cargos y el ser fumador al igual que el cargo y la edad.
- De igual manera los registros se encuentran completos en su totalidad

## III. Utilizar 3 algoritmos diferentes para identificar outliers, al menos dos de ellos deben ser métodos multidimensionales, incluyendo DBSCAN.

**Resumen de outliers detectados:**

- DBSCAN: 65
- Isolation Forest: 67
- Local Outlier Factor: 67

**Outliers de consenso (detectados por  $\geq 2$  métodos): 15**

#### IV. Explicar cómo funciona.

- Funcionamiento de DBSCAN: DBSCAN agrupa puntos que están cercanos en un espacio multidimensional (concepto de densidad), considerando outliers aquellos puntos que no pertenecen a ningún grupo. El algoritmo comienza con un punto aleatorio no visitado y toma en cuentas dos parámetros para clasificarlo como outlier o no. Si hay al menos `min_samples` puntos en el radio definido como `eps`, forma un cluster. Los puntos que no cumplen este criterio son marcados como outliers (etiqueta -1 en el data frame)
- Funcionamiento de Isolation Forest: Algoritmo especializado en detección de anomalías con datos multidimensionales. Este algoritmo funciona con el concepto de aislamiento ya que en teoría un registro atípico se encuentra aislado del grupo de datos comunes. Se crean múltiples árboles de aislamiento (por defecto 100, parámetro que se puede modificar). En cada árbol, se seleccionan atributos y puntos de división al azar en los cuales en teoría los outliers necesitan menos divisiones para ser aislados. La puntuación de anomalía se basa en la profundidad promedio necesaria para aislar un punto, criterio para detectar los outliers. Se marca como -1 en nuestro data frame si se consideran anómalos.
- El último algoritmo es el Local Outlier Factor (LOF). Es un algoritmo de detección de anomalías basado en la densidad local de los datos. Es especialmente útil para encontrar outliers en distribuciones irregulares y clusters de diferentes densidades. El funcionamiento se encarga de medir qué tan aislado está un punto en comparación con sus vecinos calculando su densidad individual.

Para cada punto se calcula sus vecinos más cercanos y después la distancia alcanzable. Por último se calcula la densidad local para el cálculo del LOF score que será comparado con el de sus vecinos.

#### V. Mencionar cuántos outliers identificó el algoritmo

- DBSCAN con parámetros de `radio=0.8` y número mínimo más cercano=5 se encontraron 65 outliers
- Isolation Forest con un valor del 5 % de valores anómalos esperados se encontraron 67
- LOF con un valor de 20 vecinos para la densidad local y un 5 % de outliers esperados se encontraron 67

## VI. Visualizar registros que hayan sido identificados como outliers. (Si son muchos, buscar alguna manera de agruparlos y mostrar conteos)

Conteo por método de detección:

```

detected_by
LOF                43
IsolationForest    26
DBSCAN, IsolationForest 23
DBSCAN             21
DBSCAN, IsolationForest, LOF 15
DBSCAN LOF         6
IsolationForest, LOF 3


```

Name: count, dtype: int64

|      | age | sex    | bmi    | children | smoker | region    | charges     | outlier_dbscan | outlier_iso | outlier_lof | outlier_consensus | detected_by                  |
|------|-----|--------|--------|----------|--------|-----------|-------------|----------------|-------------|-------------|-------------------|------------------------------|
| 1    | 18  | male   | 33.770 | 1        | no     | southeast | 1725.55230  | False          | False       | True        | False             | LOF                          |
| 32   | 19  | female | 28.600 | 5        | no     | southwest | 4687.79700  | True           | True        | False       | False             | DBSCAN, IsolationForest      |
| 34   | 28  | male   | 36.400 | 1        | yes    | southwest | 51194.55914 | True           | True        | False       | False             | DBSCAN, IsolationForest      |
| 39   | 60  | male   | 39.900 | 0        | yes    | southwest | 48173.36100 | False          | True        | False       | False             | IsolationForest              |
| 45   | 55  | male   | 37.300 | 0        | no     | southwest | 20630.28351 | False          | False       | True        | False             | LOF                          |
| ...  | ... | ...    | ...    | ...      | ...    | ...       | ...         | ...            | ...         | ...         | ...               | ...                          |
| 1300 | 45  | male   | 30.360 | 0        | yes    | southeast | 62592.87309 | True           | True        | True        | True              | DBSCAN, IsolationForest, LOF |
| 1301 | 62  | male   | 30.875 | 3        | yes    | northwest | 46718.16325 | True           | True        | False       | False             | DBSCAN, IsolationForest      |
| 1317 | 18  | male   | 53.130 | 0        | no     | southeast | 1163.46270  | True           | True        | True        | True              | DBSCAN, IsolationForest, LOF |
| 1318 | 35  | male   | 39.710 | 4        | no     | northeast | 19496.71917 | True           | True        | True        | True              | DBSCAN, IsolationForest, LOF |
| 1331 | 23  | female | 33.400 | 0        | no     | southwest | 10795.93733 | False          | False       | True        | False             | LOF                          |

137 rows × 12 columns


Outliers detectados por cualquier algoritmo (marcados en rojo)



VII. ¿Exactamente los mismos registros fueron identificados como outliers por cada uno de los tres algoritmos? Justifica tu respuesta)

Resumen de outliers consensuados:

|      | age | bmi    | children | charges     | detected_by                  |
|------|-----|--------|----------|-------------|------------------------------|
| 543  | 54  | 47.410 | 0        | 63770.42801 | DBSCAN, IsolationForest, LOF |
| 1300 | 45  | 30.360 | 0        | 62592.87309 | DBSCAN, IsolationForest, LOF |
| 577  | 31  | 38.095 | 1        | 58571.07448 | DBSCAN, IsolationForest, LOF |
| 819  | 33  | 35.530 | 0        | 55135.40209 | DBSCAN, IsolationForest, LOF |
| 549  | 43  | 46.200 | 0        | 45863.20500 | DBSCAN, IsolationForest, LOF |
| 1047 | 22  | 52.580 | 1        | 44501.39820 | DBSCAN, IsolationForest, LOF |
| 292  | 25  | 45.540 | 2        | 42112.23560 | DBSCAN, IsolationForest, LOF |
| 128  | 32  | 17.765 | 2        | 32734.18630 | DBSCAN, IsolationForest, LOF |
| 1318 | 35  | 39.710 | 4        | 19496.71917 | DBSCAN, IsolationForest, LOF |
| 1085 | 39  | 18.300 | 5        | 19023.26000 | DBSCAN, IsolationForest, LOF |
| 438  | 52  | 46.750 | 5        | 12592.53450 | DBSCAN, IsolationForest, LOF |
| 640  | 33  | 42.400 | 5        | 6666.24300  | DBSCAN, IsolationForest, LOF |
| 166  | 20  | 37.000 | 5        | 4830.63000  | DBSCAN, IsolationForest, LOF |
| 847  | 23  | 50.380 | 1        | 2438.05520  | DBSCAN, IsolationForest, LOF |
| 1317 | 18  | 53.130 | 0        | 1163.46270  | DBSCAN, IsolationForest, LOF |



Cada método de detección de outliers funciona bajo un principio matemático distinto, lo que explica por qué no todos coinciden en identificar los mismos valores atípicos:

- DBSCAN se basa en densidad, marcando como outliers puntos aislados en regiones

poco densas.

- LOF (Local Outlier Factor) compara la densidad local de un punto con la de sus vecinos, detectando anomalías en zonas de densidad irregular.
- Isolation Forest aísla puntos atípicos mediante divisiones aleatorias, siendo eficaz para outliers globales en distribuciones no uniformes.

Como cada método prioriza diferentes características (densidad, proximidad o separabilidad), es normal que algunos outliers solo sean detectados por uno o dos de ellos, dependiendo de su naturaleza y contexto en los datos.

## SECCIÓN 2


I. Ejecuta el algoritmo Isolation Forest (a mano, como se vio en clase). Presenta el dibujo del árbol y muestra paso a paso cómo se fueron eligiendo los nodos para formar la estructura.

Ya que el árbol quedó demasiado grande anexamos la imagen en los archivos zip, pues al tratar de incluirla en el reporte no se veía nada de los nodos, por lo que creemos que es mejor anexar aparte, pero en esta parte se explicara cómo es que se fue haciendo la partición:

- Escogemos la columna bmi
- Aleatoriamente de la columna bmi tomamos un dato(en este caso se tomó como primera instancia a 30.4)
- Escogemos una partición de los datos, de modo que vamos a dividir los datos que estén mayor a 36.97 y menor a este
- Después de esa partición que hicimos de nuestros datos se vuelve a tomar un número aleatorio uno para cada partición(en este caso se obtuvo a 32.4 y 41.2)
- Del mismo modo se parte en dos nuestros dos conjuntos de datos, en este caso para 32.4 los que sean mayor a 20.20 y menor al mismo. Para 41.2 se parte en menor a 40.32 y mayor a este.
- Así sucesivamente con cada conjunto hasta terminar nuestros datos
- Ahora bien para ver cuales son nuestros datos atípicos son lo que no tienen tanta profundidad en nuestro árbol , por ejemplo el dato de 52.6.



II. ¿Los outliers identificados mediante este método fueron los mismos que identificaron los algoritmos de la sección 1? ¿Por qué consideras que sí fue así o no fue así?



Algunos sí, pero otros no, esto se puede deber a que en la sección 1 se están tomando varias columnas para realizar el ISO, mientras que aquí se nos pide que lo hagamos sobre una columna, es decir puede ser que bmi justo 52.6 sea un dato atípico pero tomando en cuenta otras columnas deje de ser un dato atípico.

### SECCION 3

Genera un dataset sintético de nombres en español que contenga al menos 20 personas diferentes y que cada nombre aparezca de 3 formas distintas.

|   | nombre_completo | edad | carrera          | semestre |
|---|-----------------|------|------------------|----------|
| 0 | Juan Pérez      | 22   | Ingeniería Civil | 5        |
| 1 | Juan Perez      | 22   | Ingeniería Civil | 5        |
| 2 | Jhuan Peres     | 22   | Ingeniería Civil | 5        |
| 3 | María González  | 24   | Medicina         | 7        |
| 4 | Maria Gonzzalez | 24   | Medicina         | 7        |

I. Utiliza técnicas de preprocesamiento (limpieza y algoritmos fonéticos) y tres algoritmos de comparación difusa para agrupar correctamente las 3 formas de cada uno de los 20 nombres.

- Limpieza de nombres:

|   | nombre_completo | edad | carrera          | semestre | nombre_limpio  |
|---|-----------------|------|------------------|----------|----------------|
| 0 | Juan Pérez      | 22   | Ingeniería Civil | 5        | juan perez     |
| 1 | Juan Perez      | 22   | Ingeniería Civil | 5        | juan perez     |
| 2 | Jhuan Peres     | 22   | Ingeniería Civil | 5        | jhuan peres    |
| 3 | María González  | 24   | Medicina         | 7        | maria gonzalez |
| 4 | Maria Gonzzalez | 24   | Medicina         | 7        | maria gonzalez |

- Algoritmos foneticos:

|   | nombre_completo | edad | carrera          | semestre | nombre_limpio  | soundex | nysiis     | metaphone |
|---|-----------------|------|------------------|----------|----------------|---------|------------|-----------|
| 0 | Juan Pérez      | 22   | Ingeniería Civil | 5        | juan perez     | J516    | JANPAR     | JNPRS     |
| 1 | Juan Perez      | 22   | Ingeniería Civil | 5        | juan perez     | J516    | JANPAR     | JNPRS     |
| 2 | Jhuan Peres     | 22   | Ingeniería Civil | 5        | jhuan peres    | J516    | JANPAR     | JNPRS     |
| 3 | María González  | 24   | Medicina         | 7        | maria gonzalez | M625    | MARAGANSAL | MRKNSLS   |
| 4 | Maria Gonzzalez | 24   | Medicina         | 7        | maria gonzalez | M625    | MARAGANSAL | MRKNSLS   |

II. Los algoritmos de comparación difusa que se deben utilizar son:


- Jaro-Winkler
- Demerau-Levenshtein

|    | nombre_completo   | edad | carrera                    | semestre |
|----|-------------------|------|----------------------------|----------|
| 0  | Juan Pérez        | 22   | Ingeniería Civil           | 5        |
| 1  | María González    | 24   | Medicina                   | 7        |
| 2  | Carlos López      | 20   | Administración             | 3        |
| 3  | Ana Martínez      | 21   | Derecho                    | 4        |
| 4  | Luis Ramírez      | 23   | Arquitectura               | 6        |
| 5  | Sofía Hernández   | 19   | Psicología                 | 2        |
| 6  | Jorge Gutiérrez   | 25   | Ingeniería Industrial      | 8        |
| 7  | Patricia Sánchez  | 22   | Contaduría                 | 5        |
| 8  | Ricardo Torres    | 20   | Biología                   | 3        |
| 9  | Gabriela Mendoza  | 21   | Enfermería                 | 4        |
| 10 | Fernando Castro   | 24   | Ingeniería en Sistemas     | 7        |
| 11 | Daniela Ruiz      | 19   | Diseño Gráfico             | 2        |
| 12 | Roberto Vargas    | 23   | Comunicación Social        | 6        |
| 13 | Adriana Silva     | 22   | Educación                  | 5        |
| 14 | Miguel Ángel Díaz | 25   | Matemáticas                | 8        |
| 15 | Claudia Rojas     | 20   | Química                    | 3        |
| 16 | Oscar Méndez      | 21   | Economía                   | 4        |
| 17 | Laura Jiménez     | 24   | Antropología               | 7        |
| 18 | Andrés Navarro    | 19   | Filosofía                  | 2        |
| 19 | Isabel Cordero    | 22   | Historia                   | 5        |
| 20 | Francisco Mora    | 23   | Física                     | 6        |
| 21 | Lucía Peña        | 20   | Relaciones Internacionales | 3        |
| 22 | Eduardo Ríos      | 21   | Ingeniería Eléctrica       | 4        |
| 23 | Valeria Soto      | 25   | Ingeniería Química         | 8        |

## EJERCICIO EXTRA


Realizar la sección 3 inciso b) utilizando los algoritmos

### Similitud



## Coseno

Matriz de Distancia Coseno



|    | nombre_completo   | edad | carrera                    | semestre |
|----|-------------------|------|----------------------------|----------|
| 0  | Juan Pérez        | 22   | Ingeniería Civil           | 5        |
| 1  | María González    | 24   | Medicina                   | 7        |
| 2  | Carlos López      | 20   | Administración             | 3        |
| 3  | Ana Martínez      | 21   | Derecho                    | 4        |
| 4  | Luis Ramírez      | 23   | Arquitectura               | 6        |
| 5  | Sofía Hernández   | 19   | Psicología                 | 2        |
| 6  | Jorge Gutiérrez   | 25   | Ingeniería Industrial      | 8        |
| 7  | Patricia Sánchez  | 22   | Contaduría                 | 5        |
| 8  | Ricardo Torres    | 20   | Biología                   | 3        |
| 9  | Gabriela Mendoza  | 21   | Enfermería                 | 4        |
| 10 | Fernando Kastro   | 24   | Ingeniería en Sistemas     | 7        |
| 11 | Daniela Ruiz      | 19   | Diseño Gráfico             | 2        |
| 12 | Roberto Vargas    | 23   | Comunicación Social        | 6        |
| 13 | Adriana Silva     | 22   | Educación                  | 5        |
| 14 | Miguel Ángel Díaz | 25   | Matemáticas                | 8        |
| 15 | Claudia Rojas     | 20   | Química                    | 3        |
| 16 | Oscar Méndez      | 21   | Economía                   | 4        |
| 17 | Laura Jiménez     | 24   | Antropología               | 7        |
| 18 | Andrés Navarro    | 19   | Filosofía                  | 2        |
| 19 | Isabel Cordero    | 22   | Historia                   | 5        |
| 20 | Francisco Mora    | 23   | Física                     | 6        |
| 21 | Lucía Peña        | 20   | Relaciones Internacionales | 3        |
| 22 | Edwardo Ríos      | 21   | Ingeniería Eléctrica       | 4        |
| 23 | Valeria Soto      | 25   | Ingeniería Química         | 8        |