

Tarea 1

Estadística descriptiva y conceptos básicos

1. Censo de población y vivienda 2020

Cada 10 años, el Instituto Nacional de Estadística y Geografía (INEGI) levanta el Censo de Población y Vivienda con el objetivo de conocer diversas características de los habitantes de México y sus viviendas a nivel nacional, estatal, municipal, por localidad, por grupos de manzanas y hasta por manzana.

1.1. Base de datos a nivel municipio

Extraeremos directamente los sub-totales de población para cada municipio y haremos un análisis exploratorio de la población a nivel municipal.

- **Tamaño es la base de datos**

La base de datos utilizada después de filtrar únicamente los datos de municipio consta de 2469 filas y 286 columnas, el número de filas coincide con el número de municipios registrados por el INEGI en 2020. La base de datos resultante tiene un peso en memoria de 34.60 MB.

- **Población total**

Al sumar la población de todos los municipios de la base de datos para obtener la población total se obtuvo como resultado 126,014,024, lo cual coincide con la población total enunciada en el censo de población del INEGI, esto nos ayuda a verificar que nuestra base de datos tiene validez.

- **¿Por qué no filtrar o agregar sobre las localidades para cada municipio?**

Esto sería una pésima idea porque los id de los municipios no son únicos a nivel país, estos registros son únicos a nivel entidad federativa, por lo que filtrar o agregar sobre las localidades para cada municipio nos generaría errores en los datos. Además de esto la base de datos ya contiene los subtotales por municipio, por lo que realizar agregaciones sobre las localidades resulta innecesario.

1.2. Análisis de variables socioeconómicas.

- Porcentaje de población de 5 años y más que habla alguna lengua indígena.
- Porcentaje de población de 15 años y más que es analfabeta.
- ¿Existe alguna relación entre ambas variables?




Figura 1: Porcentaje de población de 5 años y más que habla alguna lengua indígena.




Figura 2: Porcentaje de población de 15 años y más que es analfabeta.




Figura 3: Relación entre las variables 'Porcentaje de población de 15 años y más que es analfabeta' y 'Porcentaje de población de 5 años y más que habla alguna lengua indígena'.

Observaciones:

■ Figura 1

En la mayoría de los municipios del país el porcentaje de población de 5 años y más que habla alguna lengua indígena se ha reducido casi a cero, sin embargo, todavía existen bastantes municipios con un porcentaje alto.

■ Figura 2

Tenemos una distribución sesgada a la izquierda en cuanto al porcentaje de población de 15 años y más que es analfabeta, con la Figura 2 es claro que hay mucho trabajo por hacer para

terminar de alfabetizar al país.

■ Figura 3

Observamos que sí existe relación entre las variables 'Porcentaje de población de 15 años y más que es analfabeta' y 'Porcentaje de población de 5 años y más que habla alguna lengua indígena', para justificar esta observación se decidió realizar algunas pruebas estadísticas:

- Coeficiente de correlación de Pearson: 0.7006
- P-value: 0.0

El valor de 0.7006 indica una correlación positiva moderadamente fuerte entre las dos variables. El p-value de 0.0 indica que la correlación observada es estadísticamente significativa.

1.3. Análisis de la distribución de población por entidad federativa




Figura 4: Distribución de la población en las entidades federativas.

- Con base en las gráficas, decide si calcular una media truncada o la mediana y compárala con la media muestral. Justifica tu elección.

La media truncada nos sirve para obtener una media sin tomar en cuenta los valores más bajos y más altos para que afecten a la media, pero ya que solo tenemos un outlier en nuestra distribución nos decidimos por calcular la mediana.

- Mediana calculada: 3,054,892
- Media muestral calculada: 3,937,938.25

Como podemos observar, la media muestral se ve afectada en gran medida por la población perteneciente al Estado de México (nuestro dato atípico), por lo tanto la mediana nos puede funcionar como un buen estimador de tendencia central.

- Calcula un estimador de dispersión de tu elección y justifica su uso.

Por el mismo motivo del punto anterior, la desviación estándar se puede ver muy afectada por el dato atípico de la distribución, por lo que en este caso usaremos como estimador de dispersión el rango intercuartílico.

- Rango intercuartílico: 3,095,940.25
- Con base en tu análisis, ¿qué puedes concluir sobre la distribución de la población en las entidades federativas?

En resumen, observamos que una buena parte de la población se concentra en el Estado de México, y otra parte considerable de la población se concentra en otros tres estados de la república, estos estados son: Ciudad de México, Nuevo León y Jalisco. Así, podemos concluir que estos estados contienen a las urbes más grandes del país y la población restante está más distribuida en el resto del país.

2. Pandemia de COVID-19 en la CDMX desde el año de 2020 a 2021

2.1. Casos, hospitalizaciones y fallecimientos

Casos por mes




Figura 5: La primera ola (2020) tuvo un crecimiento exponencial de casos, mientras que la segunda ola (2021) fue más intensa pero con una disminución más rápida.

■ Observaciones:

- En el primer mes registrado, febrero de 2020, los casos fueron mínimos (5 casos), pero aumentaron rápidamente a partir del siguiente mes.
- En enero de 2021, se registró el máximo histórico de casos (142,990).

- A partir de febrero de 2021, los casos disminuyeron gradualmente, pero hubo un repunte en julio de 2021 (118,906 casos).
- En los últimos meses de 2021, los casos se mantuvieron relativamente bajos, llegando a estar en menos de 20,000 por dos meses consecutivos.

Hospitalizaciones por mes




Figura 6: La proporción de hospitalizados fue más alta durante la primera ola (2020). A partir de 2021, la proporción de hospitalizados disminuyó significativamente, posiblemente debido a la vacunación y mejoras en el tratamiento.

■ Observaciones:

- El primer pico de hospitalizaciones ocurrió en mayo de 2020 (27.33 %), durante la primera ola.
- Durante 2021, los porcentajes de hospitalización disminuyeron gradualmente, con valores alrededor del 10 % en la mayoría de los meses.
- En los últimos meses de 2021, los porcentajes se mantuvieron relativamente bajos, con valores inferiores al 5 %.

Defunciones por mes




Figura 7: La proporción de defunciones fue más alta durante la primera ola (2020), lo que sugiere una mayor letalidad de la enfermedad en ese período. Al igual que con las hospitalizaciones, partir de 2021, la proporción de defunciones disminuyó significativamente.

■ Observaciones:

- En marzo de 2020, el porcentaje de defunciones fue del 1.88 %, pero aumentó rápidamente en los meses siguientes.
- El primer pico de defunciones ocurrió en mayo de 2020 (15.97 %), durante la primera ola.
- Durante 2021, los porcentajes de defunciones disminuyeron gradualmente, con valores inferiores al 5 % en la mayoría de los meses.

2.2. Hospitalizaciones y grupos de edad




Figura 8: Se observa que los adultos mayores presentaron los porcentajes más altos de hospitalización, mientras que los grupos más jóvenes tuvieron las tasas mas bajas. Los picos de hospitalización coinciden con las olas de la pandemia, mostrando una disminución notable a finales del 2021.

1. Grupo de edad 0-19 años

- **Tendencia general:** Este grupo tuvo el porcentaje más bajo de hospitalizaciones en comparación con los otros grupos de edad.
- **Evolucion:**
 - Al inicio de la pandemia, en marzo de 2020, el porcentaje de hospitalizados llego a su alto mas significativo (11.36 %), pero disminuyó en los meses siguientes.
 - A partir de julio de 2020, las hospitalizaciones se mantuvieron bajas (por debajo del 2 %).
 - Durante 2021, los porcentajes fueron aún más bajos, con valores cercanos o inferiores al 1 %.

2. Grupo de edad 20-39 años

- **Tendencia general:** Este grupo mostró una tendencia parecida pero con porcentajes ligeramente más altos que el grupo de 0-19.
- **Evolucion:**
 - En abril de 2020, hubo un pico de hospitalizaciones (11.33 %), seguido de una disminución gradual.
 - Durante 2021, los porcentajes fluctuaron entre 1 % y 3 %, con un ligero aumento entre febrero y mayo (alrededor del 2.6 %).
 - En diciembre de 2021, se observó el valor más bajo (0.50 %).

3. Grupo de edad 40-59 años

- **Tendencia general:** Este grupo mostró un aumento significativo en las hospitalizaciones en comparación con los grupos más jóvenes.
- **Evolucion:**
 - En mayo de 2020, se observó un pico pronunciado (29.20 %), seguido de valores altos durante la primera ola de la pandemia.
 - Durante 2021, los porcentajes se mantuvieron relativamente altos, con un segundo pico en abril de 2021 (10.26 %).
 - A partir de julio de 2021, hubo un tercer incremento, ligero pero notable, con valores inferiores al 4 % en los meses siguientes.

4. Grupo de edad 60+ años

- **Tendencia general:** Este grupo tuvo los porcentajes más altos de hospitalización en todos los meses, lo que indica que fue el más afectado.
- **Evolucion:**
 - En mayo de 2020, se observó un pico muy alto (52.09 %), seguido de un aumento continuo hasta junio de 2020 (62.99 %).
 - Durante 2021, los porcentajes se mantuvieron elevados, con un segundo pico en abril de 2021 (42.83 %).
 - A partir de junio de 2021, hubo un tercer aumento significativo, pero a finales de año volvió a bajar del 10 %.

2.3. Observaciones generales

- La primera ola (2020) fue caracterizada por un crecimiento exponencial de casos, con altos porcentajes de hospitalizados y defunciones. La segunda ola (2021) tuvo un incremento mas rapido de casos, pero con menores porcentajes de hospitalizados y defunciones, posiblemente debido a la vacunación.
- Todos los grupos de edad mostraron un aumento en las hospitalizaciones durante la primera mitad de 2020, con picos entre marzo y junio. El grupo de 60+ años fue el más afectado, seguido por el grupo de 40-59 años.
- En 2021, se observó un segundo y tercer (pero menos significativo) aumento en las hospitalizaciones, especialmente en los grupos de 40-59 y 60+ años. Los grupos más jóvenes (0-19 y 20-39 años) tuvieron porcentajes mucho más bajos durante este período.
- La gravedad de las hospitalizaciones aumentó con la edad, siendo el grupo de 60+ años el más afectado en todo momento.
- A finales de 2021, se mostro una disminución significativa en las hospitalizaciones y defunciones, posiblemente debido a la vacunación y la inmunidad adquirida.

3. Teorema Central del Límite

3.1. Considera una v.a. $X \sim U(0, 10)$. Calcula su esperanza μ y varianza σ^2 . Para $n = 5$, realiza los siguientes pasos:

1. Genera una m.a. $(X_1, X_2, \dots, X_n) = (x_1^1, x_2^1, \dots, x_n^1)$ de X
2. Calcula la media observada $\bar{x}_n^1$.
3. Repite los dos pasos anteriores $m = 10,000$ veces para obtener $\bar{x}_n^1, \bar{x}_n^2, \dots, \bar{x}_n^m$.
4. Haz un histograma de las medias observadas $\bar{x}_n^1, \bar{x}_n^2, \dots, \bar{x}_n^m$.
5. Encima del histograma, grafica la función de densidad de una $N(\mu, \frac{\sigma^2}{n})$. En estadística, coloquialmente se dice que estamos “ajustando” la distribución a la normal a los datos.
6. Repite toda la simulación para $n = 30$, $n = 100$ y $n = 200$ y presenta las cuatro gráficas en una matriz 2x2 para poder apreciar el impacto de aumentar el tamaño de muestra.




Figura 9: Histogramas de la media muestral para una distribución uniforme

Explicación de los resultados:

En la figura 9 se observa cómo, conforme aumenta el tamaño de muestra n , la distribución de la media muestral $\bar{X}$ se aproxima cada vez más a la distribución normal con media μ y varianza σ^2/n .

- Para $n = 5$, el histograma presenta mayor dispersión y una forma menos simétrica, lo cual es esperable cuando el tamaño de la muestra es pequeño.
- Para $n = 30$ y en adelante ($n = 100, 200$), se aprecia una clara forma más “acampanada” y un ajuste más cercano a la densidad normal teórica.
- Esto concuerda con el **Teorema Central del Límite**, que establece que la distribución de $\bar{X}$ tiende a ser normal a medida que n crece, sin importar la distribución de la variable original (en este caso, $X \sim U(0, 10)$).
- Asimismo, la varianza de la media muestral se reduce al aumentar n , haciendo que el histograma se concentre cada vez más alrededor de la media teórica $\mu = \frac{b+a}{2} = 5$.

3.2. Considera ahora una v.a. $X \sim \text{Bernoulli}(\theta)$, calcula su esperanza (μ) y varianza (σ^2). Fija $\theta = 0.05$, $n = 5$ y realiza exactamente los mismos pasos que el ejercicio 3.1




Figura 10: Histograma para una distribución Bernoulli

Sea $X \sim \text{Bernoulli}(0.05)$. Entonces, su esperanza teórica es

$$\mu = \mathbb{E}[X] = \theta = 0.05,$$

y su varianza es

$$\sigma^2 = \text{Var}(X) = \theta(1 - \theta) = 0.05 \times 0.95 = 0.0475$$

En la Figura 10, observamos los histogramas de la *media muestral* de X para distintos tamaños de muestra $n = 5, 30, 100, 200$. A medida que n crece:

- La media muestral $\bar{X}$ se concentra progresivamente alrededor de $\mu = 0.05$.
- La forma de los histogramas se aproxima a una distribución normal con varianza $\sigma^2/n = 0.0475/n$.
- Esto ilustra el **Teorema Central del Límite**, que establece que, conforme aumenta el tamaño de la muestra, la distribución de la media muestral converge a una distribución normal, *independientemente* de la distribución original de la variable (en este caso, bernoulli).

De esta manera, incluso partiendo de una variable aleatoria discreta con baja probabilidad de éxito, las medias muestrales presentan un comportamiento cada vez más “normal” y se ajustan de forma clara a la curva teórica.

3.3. ¿Qué pasa si en el ejercicio 3.2 usamos $\theta = 0.3$?

Si ahora consideramos $X \sim \text{Bernoulli}(0.3)$, tanto la media como la varianza de la distribución cambian en comparación con el caso anterior ($\theta = 0.05$):

$$\text{Media: } \mu = \mathbb{E}[X] = \theta = 0.3,$$

$$\text{Varianza: } \sigma^2 = \text{Var}(X) = \theta(1 - \theta) = 0.3 \times 0.7 = 0.21$$

A partir de estos valores, se pueden destacar los siguientes puntos:

1. **Valores más probables:** Con $\theta = 0.3$, la distribución bernoulli se desplaza hacia valores cercanos a 0.1 o 0.5, a diferencia de cuando $\theta = 0.05$, donde la mayor parte de la masa de probabilidad se concentraba cerca de 0.
2. **Impacto en la media muestral:** El Teorema Central del Límite garantiza que, cuando n tiende a infinito, la distribución de $\bar{X}$ converge en distribución a una normal. Es importante destacar que los parámetros de la distribución original de X influyen únicamente en la rapidez con la que se alcanza dicha convergencia, pero no en el hecho de que ésta ocurra.




Figura 11: Histograma para una distribución Bernoulli $\theta = 0.3$

3.4. Con base en la realización de este ejercicio, ¿cómo responderías a la clásica pregunta: “¿Cuán grande debe ser el tamaño de la muestra para que la Distribución Muestral de la media $\bar{X}$ se aproxime mediante el Teorema Central del Límite?”

La respuesta a esta pregunta depende en gran medida de la forma de la distribución original de la variable aleatoria X . En términos generales, se puede argumentar lo siguiente:

- Para distribuciones simétricas o moderadamente sesgadas, se ha dicho que un tamaño de muestra de alrededor de $n \geq 30$ suele ser suficiente para que la distribución muestral de la media $\bar{X}_n$ se aproxime bien a una normal. Lo anterior debe tomarse con cuidado puesto que en la Figura 10 puede verse que es necesario un valor de n mas grande.
- **Distribuciones altamente sesgadas o con colas pesadas:** En estos casos, es posible que se requiera un tamaño de muestra mayor (por ejemplo, $n \geq 50$ o incluso mayor) para lograr una buena aproximación a la normalidad, debido a que la variabilidad y la asimetría de la distribución original influyen en la velocidad de convergencia.
- **Observaciones empíricas en el ejercicio:** En el ejercicio realizado, se evidenció que al incrementar n (por ejemplo, al pasar de $n = 5$ a $n = 30$, $n = 100$ y $n = 200$), la distribución de $\bar{X}_n$ se vuelve progresivamente más “normal” y se ajusta de forma más evidente a la curva de la distribución teórica, lo que confirma empíricamente el Teorema Central del Límite.

En conclusión: No existe un valor único de n que funcione en todas las circunstancias; sin embargo, como regla empírica, se recomienda utilizar un tamaño de muestra de al menos 30 para distribuciones moderadamente simétricas. Para distribuciones con mayor asimetría o colas pesadas, es aconsejable emplear un n mayor para garantizar que la distribución muestral de la media se aproxime adecuadamente a la normalidad. Lo que si es cierto es que conforme n crezca siempre vamos a tener una mejor aproximación y en consecuencia estimaciones más confiables.

4. Modelos de recolección de datos básicos para hacer inferencia estadística

4.1. Demostración

Dado que las variables X_i, X_j dadas θ son independientes entre sí:

$$\mathbb{E}(X_i, X_j | \theta) = \mathbb{E}(X_i | \theta) \mathbb{E}(X_j | \theta) \quad (1)$$

Entonces, por la propiedad de la esperanza total:

$$\mathbb{E}(X_i, X_j) = \mathbb{E}(\mathbb{E}(X_i | \theta) \mathbb{E}(X_j | \theta)) \quad (2)$$

Notar que por ser idénticamente distribuidas X_i, X_j dados θ

$$\mathbb{E}(X_i | \theta) = \mathbb{E}(X_j | \theta) = \mathbb{E}(X | \theta) \quad (3)$$

Lo que nos lleva a:

$$\mathbb{E}(X_i, X_j) = \mathbb{E}(\mathbb{E}(X | \theta)^2) \quad (4)$$

Por otra parte, por propiedades de la esperanza condicional:

$$\mathbb{E}(\mathbb{E}(X | \theta)) = \mathbb{E}(X) \quad (5)$$

Con lo anterior en mente veamos la covarianza:

$$\text{Cov}(X_i, X_j) = \mathbb{E}(X_i, X_j) - \mathbb{E}(X_i) \mathbb{E}(X_j) \quad (6)$$

Sustituyendo nuestros resultados anteriores:

$$\text{Cov}(X_i, X_j) = \mathbb{E}(\mathbb{E}(X | \theta)^2) - \mathbb{E}(\mathbb{E}(X | \theta))^2 \quad (7)$$

Como puede verse, la anterior expresión puede verse en términos de la varianza

$$\text{Var}(\mathbb{E}(X | \theta)) = \mathbb{E}(\mathbb{E}(X | \theta)^2) - \mathbb{E}(\mathbb{E}(X | \theta))^2 = \text{Cov}(X_i, X_j) \quad (8)$$

Dado que la varianza es siempre positiva, hemos visto que la covarianza también lo es.